

Soit  $r$  un entier strictement positif. Notons  $\mathbb{S}_r$  l'ensemble des matrices de transition de taille  $r \times r$ , i.e. l'ensemble des matrices de taille  $r \times r$  de réels positifs telles que la somme de chaque ligne soit égale à 1. Considérons un paramètre  $\theta = \{P, \mu_1, \dots, \mu_r, v_1, \dots, v_r\} \in \Theta$ , où  $\Theta = \mathbb{S}_r \times \mathbb{R}^r \times (\mathbb{R}_+^*)^r$  et le modèle suivant paramétré par  $\theta$ .

Soit  $(X_k)_{0 \leq k \leq n}$  une chaîne de Markov discrète à valeurs dans  $\{1, \dots, r\}$ , de matrice de transition  $P$  et de loi initiale  $\nu$ . Cela signifie que pour tout  $1 \leq j \leq r$ ,  $\mathbb{P}_\theta(X_0 = j) = \nu_j$  et pour tout  $0 \leq k \leq n-1$  et tout  $1 \leq i, j \leq r$ ,  $\mathbb{P}_\theta(X_{k+1} = j | X_k = i) = P_{i,j}$ . On considère que cette chaîne est uniquement observée au travers des variables  $(Y_k)_{0 \leq k \leq n}$ , indépendantes conditionnellement à  $(X_k)_{0 \leq k \leq n}$  et telles que pour tout  $0 \leq \ell \leq n$ , la loi de  $Y_\ell$  sachant  $(X_k)_{0 \leq k \leq n}$  est une gaussienne de moyenne  $\mu_{X_\ell}$  et de variance  $v_{X_\ell}$ .

1. Écrire la logvraisemblance jointe de  $(X_{0:n}, Y_{0:n})$ :  $\theta \mapsto \log p_\theta(X_{0:n}, Y_{0:n})$ .

Notons  $\varphi_{\mu, \sigma^2}$  la densité de la loi gaussienne de moyenne  $\mu$  et de variance  $\sigma^2$ . Nous avons, pour tout  $\theta$ ,

$$\begin{aligned} \log p_\theta(X_{0:n}, Y_{0:n}) &= \log p_\theta(X_{0:n}) + \log p_\theta(Y_{0:n} | X_{0:n}), \\ &= \log p_\theta(X_0) + \sum_{k=1}^n \log p_\theta(X_k | X_{k-1}) + \sum_{k=0}^n \log p_\theta(Y_k | X_k), \\ &= \sum_{i=1}^r \mathbb{1}_{X_0=i} \log \nu_i + \sum_{k=1}^n \sum_{i,j=1}^r \mathbb{1}_{X_{k-1}=i, X_k=j} \log P_{i,j} \\ &\quad + \sum_{k=0}^n \sum_{i=1}^r \mathbb{1}_{X_k=i} \log \varphi_{\mu_i, v_i}(Y_k). \end{aligned}$$

2. Écrire la quantité intermédiaire de l'EM  $Q(\theta, \theta')$  pour tout  $\theta, \theta'$  :

$$Q(\theta, \theta') = \mathbb{E}_{\theta'} [\log p_\theta(X_{0:n}, Y_{0:n}) | Y_{0:n}].$$

Par la question précédente,

$$\begin{aligned} Q(\theta, \theta') &= \mathbb{E}_{\theta'} [\log p_\theta(X_{0:n}, Y_{0:n}) | Y_{0:n}], \\ &= \sum_{i=1}^r \mathbb{E}_{\theta'} [\mathbb{1}_{X_0=i} | Y_{0:n}] \log \nu_i + \sum_{k=1}^n \sum_{i,j=1}^r \mathbb{E}_{\theta'} [\mathbb{1}_{X_{k-1}=i, X_k=j} | Y_{0:n}] \log P_{i,j} \\ &\quad + \sum_{k=0}^n \sum_{i=1}^r \mathbb{E}_{\theta'} [\mathbb{1}_{X_k=i} | Y_{0:n}] \log \varphi_{\mu_i, v_i}(Y_k). \end{aligned}$$

3. Écrire cette quantité en faisant apparaître les probabilités

$$\omega_{k-1,k}^\theta(i, j) = \mathbb{P}_\theta(X_{k-1} = i, X_k = j | Y_{0:n}),$$

pour  $1 \leq k \leq n$  et

$$\tilde{\omega}_k^\theta(i) = \mathbb{P}_\theta(X_k = i | Y_{0:n}),$$

pour  $0 \leq k \leq n$ .

Il suffit d'appliquer la question précédente :

$$Q(\theta, \theta') = \sum_{i=1}^r \tilde{\omega}_0^{\theta'}(i) \log \nu_i + \sum_{k=1}^n \sum_{i,j=1}^r \omega_{k-1,k}^{\theta'}(i, j) \log P_{i,j} + \sum_{k=0}^n \sum_{i=1}^r \tilde{\omega}_k^{\theta'}(i) \log \varphi_{\mu_i, v_i}(Y_k).$$

4. À l'itération  $p \geq 0$ , on dispose de l'estimation  $\hat{\theta}^{(p)}$ . Écrire l'estimateur  $\hat{\theta}^{(p+1)}$  en maximisant  $\theta \mapsto Q(\theta, \hat{\theta}^{(p)})$ .

On peut montrer que la fonction  $\theta \mapsto Q(\theta, \theta^{(p)})$  admet un maximum unique obtenu en résolvant l'équation  $\nabla_{\theta} Q(\theta, \theta^{(p)}) = 0$ .

- Pour tout  $1 \leq i \leq r$  et tout  $1 \leq j \leq r-1$ , en remarquant que  $P_{i,r} = 1 - \sum_{\ell=1}^{r-1} P_{i,\ell}$ ,

$$\partial_{P_{i,j}} Q(\theta, \theta^{(p)}) = \sum_{k=1}^n \frac{\omega_{k-1,k}^{\theta^{(p)}}(i, j)}{P_{i,j}} - \sum_{k=1}^n \frac{\omega_{k-1,k}^{\theta^{(p)}}(i, r)}{P_{i,r}}.$$

On obtient donc que pour tout  $1 \leq i \leq r$  et tout  $1 \leq j \leq r-1$ ,

$$\sum_{k=1}^n \frac{\omega_{k-1,k}^{\theta^{(p)}}(i, j)}{P_{i,j}} = \sum_{k=1}^n \frac{\omega_{k-1,k}^{\theta^{(p)}}(i, r)}{P_{i,r}},$$

puis que

$$P_{i,j}^{(p+1)} = \frac{\sum_{k=1}^n \omega_{k-1,k}^{\theta^{(p)}}(i, j)}{\sum_{k=1}^n \tilde{\omega}_{k-1}^{\theta^{(p)}}(i, j)}.$$

- Pour tout  $1 \leq i \leq r$ ,

$$\partial_{\mu_i} Q(\theta, \theta^{(p)}) = \frac{1}{v_i} \sum_{k=0}^n \tilde{\omega}_k^{\theta^{(p)}}(i) (Y_k - \mu_i).$$

Ainsi,

$$\mu_i^{(p+1)} = \frac{\sum_{k=1}^n \tilde{\omega}_k^{\theta^{(p)}}(i) Y_k}{\sum_{k=0}^n \tilde{\omega}_k^{\theta^{(p)}}(i)}.$$

- Pour tout  $1 \leq i \leq r$ ,

$$\partial_{v_i} Q(\theta, \theta^{(p)}) = \sum_{k=0}^n \tilde{\omega}_k^{\theta^{(p)}}(i) \left( -\frac{1}{2v_i} + \frac{1}{2v_i^2} (Y_k - \mu_i)^2 \right).$$

Ainsi,

$$v_i^{(p+1)} = \frac{\sum_{k=0}^n \tilde{\omega}_k^{\theta^{(p)}}(i) (Y_k - \mu_i^{(p+1)})^2}{\sum_{k=1}^n \tilde{\omega}_k^{\theta^{(p)}}(i)}.$$

5. Dans le cas où on souhaite également apprendre la loi initiale de la chaîne de Markov et que  $\theta = \{P, \mu_1, \dots, \mu_r, v_1, \dots, v_r, \nu_1, \dots, \nu_r\}$ , donner les équations de mise à jour de  $\nu$ .

En utilisant la question 4, on obtient, pour tout  $1 \leq i \leq r-1$ ,

$$\partial_{\nu_i} Q(\theta, \theta^{(p)}) = \frac{\tilde{\omega}_0^{\theta^{(p)}}(i)}{\nu_i} - \frac{\tilde{\omega}_0^{\theta^{(p)}}(r)}{\nu_r},$$

et

$$\nu_i^{(p+1)} = \tilde{\omega}_0^{\theta^{(p)}}(i).$$

6. Calculer le gradient de la logvraisemblance des observations :  $\theta \mapsto \nabla_{\theta} \log p_{\theta}(Y_{0:n})$ .

On remarque que pour tout  $\theta, \theta'$  et en notant  $\mathbf{X} = \{1, \dots, r\}$ ,

$$\begin{aligned} \log p_\theta(Y_{0:n}) &= \sum_{x_{0:n} \in \mathbf{X}^{n+1}} \log p_\theta(Y_{0:n}) \mathbb{P}_{\theta'}(X_{0:n} = x_{0:n} | Y_{0:n}) \\ &= \sum_{x_{0:n} \in \mathbf{X}^{n+1}} \log \frac{p_\theta(x_{0:n}, Y_{0:n})}{\mathbb{P}_\theta(X_{0:n} = x_{0:n} | Y_{0:n})} \mathbb{P}_{\theta'}(X_{0:n} = x_{0:n} | Y_{0:n}), \\ &= \sum_{x_{0:n} \in \mathbf{X}^{n+1}} \log p_\theta(x_{0:n}, Y_{0:n}) \mathbb{P}_{\theta'}(X_{0:n} = x_{0:n} | Y_{0:n}) \\ &\quad - \sum_{x_{0:n} \in \mathbf{X}^{n+1}} \log \mathbb{P}_\theta(x_{0:n} | Y_{0:n}) \mathbb{P}_{\theta'}(X_{0:n} = x_{0:n} | Y_{0:n}), \end{aligned}$$

Ainsi,

$$\nabla_{\theta=\theta'} \log p_\theta(Y_{0:n}) = \mathbb{E}_{\theta'} [\nabla_{\theta=\theta'} \log p_\theta(X_{0:n}, Y_{0:n}) | Y_{0:n}],$$

car

$$\begin{aligned} \nabla_{\theta=\theta'} \sum_{i=1}^n \log \mathbb{P}_\theta(X_{0:n} = x_{0:n} | Y_{0:n}) \mathbb{P}_{\theta'}(X_{0:n} = x_{0:n} | Y_{0:n}) \\ = \nabla_{\theta=\theta'} \left( \sum_{x_{0:n} \in \mathbf{X}^{n+1}} \mathbb{P}_\theta(X_{0:n} = x_{0:n} | Y_{0:n}) \right) = 0. \end{aligned}$$

Le score (gradient de la logvraisemblance) se calcule à l'aide d'une espérance conditionnelle du même type que la quantité intermédiaire de l'EM.

7. En déduire un algorithme de mise à jour des paramètres de type "descente de gradient".

Si l'on souhaite utiliser une méthode du premier ordre on peut écrire, pour  $p \geq 0$ ,

$$\tilde{\theta}^{(p+1)} = \tilde{\theta}^{(p)} + \gamma_p \mathbb{E}_{\theta^{(p)}} [\nabla_{\theta=\theta^{(p)}} \log p_\theta(X_{0:n}, Y_{0:n}) | Y_{0:n}],$$

où les  $\{\gamma_p\}_{p \geq 0}$  sont des pas positifs.

8. **Bonus:** Calcul des  $\omega_{k-1,k}^\theta(i, j)$ ,  $1 \leq k \leq n$ ,  $1 \leq i, j \leq r$ .

- (a) Montrer que l'on peut calculer récursivement  $\mathbb{P}_\theta(X_k = i | Y_{0:k})$ ,  $0 \leq k \leq n$ ,  $1 \leq i, j \leq r$ .
- (b) Montrer que l'on peut calculer récursivement, de  $k = n$  à  $k = 0$ ,  $\mathbb{P}_\theta(X_k = i | Y_{0:n})$ ,  $0 \leq k \leq n$ ,  $1 \leq i \leq r$ .
- (c) Conclure.